

Taller de Investigación con Modelización Matemática y Datos

*PredictBuy: un modelo de predicción de compra para las
tiendas e-commerce*

Manuela Dourisboure (110861)

Magdalena Mormandi (110718)

Facultad de Ingeniería de la Universidad de Buenos Aires

Informe

A continuación, se desarrollará el trabajo práctico del Taller de Investigación con Modelización Matemática y datos. El proyecto surge con el objetivo de ofrecer una herramienta de análisis a las tiendas e commerce, que les permita predecir si los carritos abandonados en las tiendas online serán compras efectivas o no. De esta forma, la empresa puede utilizar este servicio para reorientar sus estrategias de marketing, analizar si hay más carritos abandonados que compras efectivas, etc.

Para el desarrollo de este proyecto, se trabajó con Google Collab para elaborar el código, planteando un modelo de Machine Learning (Random Forest) ya que era la herramienta más conveniente para un proyecto de predicción.


En un principio, trabajamos con un dataset de internet llamado “Online Shoppers Intention” que se utilizó para el entrenamiento del modelo, tomando 1 los carritos efectivos y 0 los intentos abandonados. Previo a la elaboración del modelo, se realizó una limpieza de datos innecesarios que podrían generar “ruido” en el modelo.

Una vez realizado el modelo, se estudiaron las variables más importantes que tenían un impacto en la predicción del modelo. La principal fue “PageValues”, que representa la influencia de una página web visitada por el usuario, que impacta fuertemente en la efectivización de la compra; ya que un valor alto sugiere que hay un interés en comprar. A su vez, hay otras variables relevantes como “ProductRelated_Duration”, “ExitRates”, “ProductRelated” y “BounceRates” que brindan información en el compromiso y la intención del usuario en comprar los productos.

Luego del análisis de las variables, se estudiaron las métricas del modelo; que acá se destaca “Recall de compra”, si la tienda quiere detectar la mayor cantidad de usuarios que tienen intención de comprar, “Precisión de compra” si la empresa solo quiere enfocar su estrategia en usuarios donde exista una probabilidad media-alta de compra, y “AUC-ROC” para evaluar que tan bien separa el modelo entre compradores y no compradores.

Como se mencionó anteriormente, el producto final es brindar una herramienta de análisis y gestión que sirva como predicción para las tiendas e commerce. Para ello, la presentación sería una página web donde la empresa cargue su dataset descargado del sistema y los suba a la plataforma. Se brindarán indicaciones de las variables que debe contener el dataset para que el modelo pueda trabajar en él.

En el trabajo, se utilizó la plataforma Streamlit, una herramienta que fue útil para crear la página web a partir del código. La página principal es simple, el usuario carga el dataset como csv con las indicaciones dadas y el modelo hace la predicción.



Problemas con los datos reales

Nuestra intención era utilizar un ecommerce real para probar nuestro modelo. Obtuvimos la página web de un emprendimiento pequeño de venta de mates, y descargamos Google Analytics para obtener los datos de la compra. El primer problema que tuvimos era que el emprendimiento ya estaba fuera de uso, por lo que los únicos datos que estaban disponibles eran los datos de las compras exitosas realizadas. Por otro lado, Google Analytics solo ofrece información de visitas a la página realizadas posterior a su instalación, por lo que no teníamos datos de compras no exitosas, solo las realizadas. Le pedimos a distintas personas que simulen sesiones no exitosas, entrando a la web, visitando distintas páginas, y luego abandonando sus carritos, para obtener datos de compras no realizadas.

Otro inconveniente que tuvimos con estos datos era la calidad de las variables que pudimos obtener. El dataset original que utilizamos para entrenar el modelo contiene 17 variables que describen tanto el tipo de usuario que visita la página (si es un usuario recurrente o nuevo, su región geográfica, y el mes en el que visitó la página) como las acciones que este realizó dentro de la página (si visitó pestañas informativas, pestañas de productos, el tiempo que estuvo en cada pestaña, y cuál fue la última pestaña que visitó). En el caso de los datos que obtuvimos con la plataforma e-commerce real, las variables que logramos obtener desde google analytics sobre los carritos abandonados y las que obtuvimos de la nube del e-commerce sobre las compras exitosas eran únicamente descriptivas de las características más generales del usuario y de la compra realizada. Las variables eran: región del usuario, fecha de compra, monto total de la compra, producto comprado, método de pago, y método de envío. Ninguna variable se refería al comportamiento del usuario previo a la compra en la página, por lo que no nos permitía realizar ninguna conclusión para hacer predicciones sobre nuevos usuarios acerca de si era más probable que realicen la compra o no. Además la cantidad de datos obtenidos era muy baja (70 compras registradas), por lo que los datos de entrenamiento para el modelo podían resultar escasos.

Por estos motivos, decidimos probar el modelo con los datos del dataset original con el que creamos y entrenamos el modelo. Para el entrenamiento se utilizó un 80% de los datos del dataset, para poder utilizar el 20% restante para el testeo y poder calcular qué tan precisa fue la predicción. Se probó primero con una muestra pequeña de 100 datos, y luego con el total de los datos de testeo.

Aplicación real en empresas

Como se explicó antes, el dataset que utilizamos para entrenar el modelo contiene variables muy específicas, que no cualquier e-commerce puede obtener de forma simple, o sin requerimiento de herramientas especiales y conocimientos de análisis de datos.

Luego del desarrollo del trabajo, se reconoció que es complejo hacer coincidir las variables de un dataset real con el utilizado en el entrenamiento del modelo de machine learning. Dicho esto, se aconseja que si este modelo es para ser aplicado hoy en día, sería óptimo reentrenar el modelo con variables más abarcativas que sean posibles de extraer de mi tienda nube, pixel o google analytics. En nuestro caso, no pudimos realizarlo ya que el único dataset útil que conseguimos cuando iniciamos el proyecto era extraído de google y no sabíamos el impacto de las variables. Por ende, lo ideal sería ver qué columnas ofrece

“mi tienda nube” u otro servicio de ecommerce que usen las empresas, y entrenar el dataset con esas variables. De esta forma, nos aseguramos que es un modelo más amplio y que puede ser aplicado a distintas tiendas. No obstante, otra opción es que parte del “producto” sea recibir los datos de la empresa y, además de limpiarlos, re-ordenarlos para que coincidan con las variables que tiene el modelo. De esta manera, podríamos asegurarnos que el dataset podrá ser procesado por el modelo de machine learning y su predicción sería acertada.

Conclusión

En conclusión, a lo largo de este trabajo pudimos desarrollar un modelo de machine learning dentro del marco de investigación de datos. Si bien, no pudimos utilizar el dataset de un ecommerce real, ya conocemos qué cambios deberíamos hacer en caso de querer llevar a cabo este proyecto. A su vez, aprendimos sobre la importancia de las variables y el rol que cumplen en un modelo de este tipo. Creemos que este proyecto podría ser útil para brindar una nueva herramienta para las tiendas e commerce, que les contribuya en el análisis de datos y les permita estudiar al cliente.